



BURDUR MEHMET AKİF ERSOY ÜNİVERSİTESİ

Gölkhisar Uygulamalı Bilimler Yüksekokulu

BÜYÜK VERİ DERSİ

GRUP İSMİ: BONGOMYA KRALLIĞI

PROJE KONUSU: OSCC VERİLERİNDE PCA (TEMEL BİLEŞEN ANALİZİ), CLAHE VE KERNEL METHODLARININ İNCELLENMESİ

Öğrenci Ad-Soyad:

1-BURHAN ÜSTÜBİ (LİDER)-2012903069

2- ELİF ALTINTAŞ-1912901001

3-EBUBEKİR KARTAL-2112903304

4- ABDULLAH FURKAN ASLAN-2112903044

5- OĞUZHAN POLAT- 1912901032

ARALIK 2024

BURDUR

İçindekiler

ŞEKİLLER DİZİNİ	2
ÖZET	3
GİRİŞ	4
Literatür Özeti.....	4
3. GEREÇ VE YÖNTEM.....	5
3.1. Kullanılan Veri Seti	5
3.2. Uygulanan Yöntemler.....	6
3.2.1. CLAHE Metodu	6
3.2.2. Kernel PCA Uygulaması	7
3.2.3. CLAHE Uygulanmış Verilere Kernel PCA Uygulaması	9
3.2.4. Kernel PCA Uygulanmış Verilere CLAHE Metodu Uygulaması	10
3.3. Kullanılan Araçlar ve Ortam.....	10
4. BULGULAR	11
5. TARTIŞMA.....	11
SONUÇ VE ÖNERİLER	13
KAYNAKÇA.....	14

ŞEKİLLER DİZİNİ

1. Şekil 3. 1: Normal hücre.....	5
2. Şekil 3. 2: OSCC hücresi.....	5
3. Şekil 3. 3: Clahe Metodu.....	6
4. Şekil 3. 4: Ham veri Sağlıklı.....	7
5. Şekil 3. 5: CLAHE uygulanmış veri.....	7
6. Şekil 3. 6: Kontrast Değişim Grafiği.....	7
7. Şekil 3. 7: Kernel PCA.....	8
8. Şekil 3. 8: Ham veri Sağlıklı.....	8
9. Şekil 3. 9: Kernel PCA uygulanmış.....	8
10. Şekil 3. 10: Ham veriler üzerinde PCA Grafiği.....	9
11. Şekil 3. 11: Kernel veriler üzerinde PCA Grafiği.....	9
12. Şekil 3. 12: CLAHE uygulanmış.....	9
13. Şekil 3. 13: CLAHE ve Kernel PCA.....	9
14. Şekil 3. 14: Kernel Uygulanmış Veri.....	10
15. Şekil 3. 15: Kernel ve CLAHE Uygulanmış Veri.....	10
16. Şekil 3. 16 : Elde Edilen Sonuçlar.....	11

ÖZET

Bu projede, oral skuamöz hücreli karsinom (OSCC) hastalığının tespitine yönelik patolojik veriler kullanılarak Contrast Limited Adaptive Histogram Equalization (CLAHE) ve Kernel Principal Component Analysis (Kernel PCA) yöntemleri uygulanmıştır. Çalışmanın ilk aşamasında, CLAHE yöntemi ile görüntü verileri üzerinde kontrast iyileştirmesi sağlanmış ve gürültü azaltma işlemleri gerçekleştirilmiştir. Ardından, Kernel PCA yöntemi ile verilerde boyut azaltma işlemi yapılmış ve özniteliklerin daha anlamlı hale getirilmesi sağlanmıştır.

Bu süreçte, kullanılan yöntemler sayesinde veri boyutu düşürülerek öznitelik çıkarımı optimize edilmiş ve OSCC teşhisinde kullanılan makine öğrenmesi modellerinin performansı artırılmıştır. Elde edilen sonuçlar, önerilen yöntemlerin OSCC tespiti için etkili bir yaklaşım sunduğunu göstermiştir. Çalışma hem klinik teşhis süreçlerini desteklemek hem de patolojik veri analizi alanında yeni bir perspektif sunmak amacıyla gerçekleştirilmiştir.

Anahtar Kelimeler: OSCC, Kernel PCA, CLAHE, Boyut Azaltma

ABSTRACT

In this project, pathological data were utilized for the detection of oral squamous cell carcinoma (OSCC) using Contrast Limited Adaptive Histogram Equalization (CLAHE) and Kernel Principal Component Analysis (Kernel PCA) methods. In the initial phase, the CLAHE method was applied to enhance the contrast of image data and reduce noise. Subsequently, dimensionality reduction was performed using the Kernel PCA method, enabling the extraction of more meaningful features.

Through the implemented methods, the data dimensionality was reduced, and feature extraction was optimized, leading to improved performance of machine learning models in OSCC diagnosis. The results demonstrated that the proposed approach provides an effective solution for OSCC detection. This study was conducted to support clinical diagnosis processes and offer a new perspective in the field of pathological data analysis.

Keywords: OSCC, Kernel PCA, CLAHE, Dimensionality Reduction

GİRİŞ

Oral skuamöz hücreli karsinom (OSCC), dünya genelinde en yaygın görülen ağız kanseri türlerinden biridir ve erken teşhis edilmediği durumlarda yüksek mortalite oranlarıyla ilişkilidir. Günümüzde hastalık teşhisinde kullanılan yöntemler, genellikle zaman alıcı ve yüksek maliyetlidir. Bu durum, daha hızlı, maliyet etkin ve yüksek doğruluğa sahip teşhis yöntemlerinin geliştirilmesi gerekliliğini ortaya koymaktadır.

Bu çalışmada, OSCC teşhisinde kullanılan görüntü verilerinin işlenmesi ve analizine yönelik yeni bir yaklaşım sunulmuştur. İlk olarak, OSCC'ye ait patolojik görüntüler üzerinde Contrast Limited Adaptive Histogram Equalization (CLAHE) yöntemi uygulanarak görüntülerin kontrastı iyileştirilmiş ve gürültü azaltılmıştır. Bu adım, ham görüntülerin daha anlamlı hale getirilmesine olanak sağlamış ve görüntülerin analizi için uygun bir temel oluşturmuştur.

Ardından, Kernel Principal Component Analysis (Kernel PCA) yöntemi ile veriler üzerinde boyut azaltma işlemi gerçekleştirilmiştir. Bu işlem, büyük veri kümelerindeki gereksiz bilgilerin elenmesini sağlamış, veri setinin karmaşıklığını azaltmış ve öznitelik çıkarım sürecini optimize etmiştir. Elde edilen bu işlem sonrası veriler, makine öğrenmesi modelleriyle analiz edilmeye hazır hale getirilmiştir.

Bu çalışmanın amacı, OSCC teşhisinde kullanılan geleneksel yöntemlere alternatif olarak, hem doğruluğu artırılmış hem de daha hızlı ve maliyet etkin bir süreç sunmaktır. Önerilen yaklaşımın sonuçlarının, klinik uygulamalarda teşhis sürecine katkı sağlaması ve OSCC hastalığının erken teşhis oranını artırması hedeflenmektedir.

Literatür Özeti

Oral skuamöz hücreli karsinom (OSCC), dünya genelinde ciddi sağlık sorunlarına yol açan bir kanser türü olarak literatürde geniş bir şekilde ele alınmıştır. OSCC teşhisinde genellikle biyopsi ve histopatolojik inceleme gibi yöntemler kullanılmakta, ancak bu yöntemlerin zaman alıcı ve maliyetli olduğu vurgulanmaktadır. Ayrıca, bu süreçlerde hata oranlarının yüksek olabilmesi, erken teşhis ve doğru tanı için yenilikçi yaklaşımların geliştirilmesi gerekliliğini doğurmuştur.

Literatürde, OSCC teşhisinde dijital görüntü işleme ve makine öğrenmesi yöntemlerinin kullanımı giderek artmaktadır. Görüntü işleme teknikleri arasında, Contrast Limited Adaptive Histogram Equalization (CLAHE) yöntemi, tıbbi görüntülerin kontrastını iyileştirme ve gürültüyü azaltma konusunda etkili bir araç olarak öne çıkmaktadır. CLAHE'nin, özellikle düşük kaliteli ve kontrastı yetersiz

görüntülerde, detayların daha belirgin hale getirilmesi için kullanıldığı çalışmalar bulunmaktadır (Pizer et al., 1987; Zuiderveld, 1994).

Bunun yanı sıra, veri boyutunu azaltmak ve daha anlamlı öznitelikler elde etmek için Kernel Principal Component Analysis (Kernel PCA) gibi boyut azaltma yöntemleri sıklıkla tercih edilmektedir. Kernel PCA, doğrusal olmayan veri kümelerindeki temel bileşenleri daha iyi temsil edebilme kapasitesi sayesinde, biyomedikal veri analizi çalışmalarında önemli bir yere sahiptir. Literatürde, Kernel PCA'nın yüksek boyutlu tıbbi görüntülerdeki hesaplama maliyetini azalttığı ve makine öğrenmesi modellerinin doğruluğunu artırdığına dair bulgular bulunmaktadır (Schölkopf et al., 1998; Mika et al., 1999).

Son yıllarda yapılan çalışmalar, CLAHE ve Kernel PCA gibi yöntemlerin bir arada kullanılarak OSCC teşhisinde başarılı sonuçlar elde edildiğini göstermektedir. Örneğin, Zhang et al. (2020) çalışmasında CLAHE ve boyut azaltma yöntemlerinin birleşimiyle makine öğrenmesi tabanlı OSCC teşhisinde %90'ın üzerinde doğruluk elde edilmiştir. Benzer şekilde, Liu ve arkadaşları (2019), tıbbi görüntüler üzerinde CLAHE ve Kernel PCA'nın entegrasyonu sayesinde hem analiz sürecini hızlandırmış hem de teşhis doğruluğunu artırmıştır.


Bu çalışma, mevcut literatürdeki yöntemlere dayanarak, CLAHE ve Kernel PCA'nın bir arada kullanımını OSCC teşhisi için optimize etmeyi ve bu süreçte elde edilen sonuçların makine öğrenmesi modellerine entegrasyonunu sağlamayı amaçlamaktadır.

3. GEREÇ VE YÖNTEM


Bu bölümde, proje kapsamında kullanılan veri seti, uygulanan veri işleme teknikleri ve sınıflandırma yöntemleri detaylı bir şekilde açıklanmaktadır.

3.1. Kullanılan Veri Seti

Çalışmada, Kaggle platformunda herkese açık olarak paylaşılan ve oral skuamöz hücreli karsinom (OSCC) teşhisi için kullanılan bir veri seti tercih edilmiştir. Bu veri seti, ham görüntü verilerini ve etiketlerini içermektedir. Veri seti, görüntülerin farklı sınıflara ait olduğunu gösterecek şekilde etiketlenmiştir.



Şekil 3. 1: Normal hücre



Şekil 3. 2: OSCC hücresi

3.2. Uygulanan Yöntemler

Proje kapsamında, veri işleme ve sınıflandırma süreçleri dört farklı aşamada gerçekleştirilmiştir. Bu süreçler sırasıyla aşağıda açıklanmıştır:

3.2.1. CLAHE Metodu

Ham görüntülere ilk olarak CLAHE (Contrast Limited Adaptive Histogram Equalization) yöntemi uygulanmıştır. CLAHE, görüntü kontrastını iyileştirmek ve detayları ön plana çıkarmak amacıyla kullanılan bir histogram eşitleme tekniğidir. Bu yöntem, özellikle düşük kontrastlı tıbbi görüntülerde detayları vurgulamak için oldukça etkilidir.

Clahe.py:

```
from PIL import Image
import os
import cv2
import numpy as np

# Resimlerin bulunduğu klasörün tam yolunu belirt
folder_path = r'C:\Users\burha\Desktop\ESKİ\OCSS\KERNEL\TEST\OSCC'

# Çıktı dosyalarının kaydedileceği klasör
output_folder_path = r'C:\Users\burha\Desktop\ESKİ\OCSS\KERNEL-CLAHE\TEST\OSCC'

# Eğer çıktı klasörü mevcut değilse oluştur
if not os.path.exists(output_folder_path):
    os.makedirs(output_folder_path)

def apply_clahe(img, clip_limit=1.0, grid_size=8):
    # Görüntüyü numpy dizisine çevir
    img_np = np.array(img)

    # CLAHE uygulama
    clahe = cv2.createCLAHE(clipLimit=clip_limit, tileGridSize=(grid_size, grid_size))
    clahe_img = clahe.apply(img_np)

    return Image.fromarray(clahe_img)


# Klasördeki tüm dosyaları al
for filename in os.listdir(folder_path):
    # Dosya uzantısını kontrol et
    if filename.lower().endswith(('.jpg', '.jpeg', '.png')): # JPG, JPEG veya PNG dosyalarını al
        # Resmin tam yolunu oluştur
        img_path = os.path.join(folder_path, filename)

        # Resmi oku
        img = Image.open(img_path).convert('L') # Gri tonlamalı olarak oku


        # Resmin doğru bir şekilde açılıp açılmadığını kontrol et
        if img is not None:
            # CLAHE uygula
            clahe_img = apply_clahe(img)

            # Sonucu farklı klasöre kaydet
            output_path = os.path.join(output_folder_path, 'clahe_' + filename)
            clahe_img.save(output_path)
            print(f"CLAHE uygulandı: {output_path}")
        else:
            print(f"Resim açılmadı: {img_path}")
    else:
        print(f"Geçersiz dosya uzantısı: {filename}")
```

Şekil 3. 3: Clahe Metodu




Şekil 3. 4: Ham veri Sağlıklı



Şekil 3. 5: CLAHE uygulanmış veri

HAM VE CLAHE UYGULANMIŞ VERİLERDEKİ KONTRAST DEĞİŞİMİ



Şekil 3. 6: Kontrast Değişim Grafiği

CLAHE uygulanmış verilerde kontrastın artışı ile daha net görüntüler elde ettik. %5.42 lik bir artış sağladık.

3.2.2. Kernel PCA Uygulaması

Ham verilere boyut indirgeme işlemi yapmak için Kernel PCA (Principal Component Analysis) yöntemi uygulanmıştır. Kernel PCA, geleneksel PCA yönteminin doğrusal olmayan verilerde daha etkili bir şekilde çalışmasını sağlamak amacıyla çekirdek (kernel) yöntemlerini kullanır. Bu işlem, veri setindeki önemli özelliklerin çıkarılmasına ve boyutun azaltılmasına olanak tanır.

Kernel.py:

```
import numpy as np
import matplotlib.pyplot as plt
from PIL import Image
import glob
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
import os

# Görüntü dosyalarını belirtilen yoldan yükleme
file_paths = glob.glob(r'C:\Users\burha\Desktop\ESKİ\OCSS\CLAE\TEST\OSCC\*.jpg')
images = [Image.open(file) for file in file_paths]
images = [img.resize((128, 128)) for img in images] # Görüntü boyutunu küçültme

# Görüntüleri numpy dizisine dönüştürme
image_arrays = np.array([np.array(img).flatten() for img in images])

# Veriyi ölçekle
scaler = StandardScaler()
images_scaled = scaler.fit_transform(image_arrays)

# PCA uygulayın
pca = PCA(n_components=50) # Korunacak bileşen sayısı
images_pca = pca.fit_transform(images_scaled)


# PCA ile yeniden yapılandırılmış görüntüleri elde et
images_reconstructed = pca.inverse_transform(images_pca)
images_reconstructed = scaler.inverse_transform(images_reconstructed) # Ölçeklemeyi geri al

# Kaydetme klasörünü belirt
save_path = r'C:\Users\burha\Desktop\ESKİ\OCSS\CLAE-KERNEL\TEST\OSCC'
if not os.path.exists(save_path):
    os.makedirs(save_path)


# Yeniden yapılandırılmış görüntüleri kaydet
for i, img_array in enumerate(images_reconstructed):
    img = Image.fromarray(np.uint8(img_array.reshape(128, 128))) # Boyut ve kanalı düzenleyin
    img.save(f'{save_path}\\reconstructed_image_{i}.jpg')

# İsteğe bağlı: Bir yeniden yapılandırılmış görüntüyü göster
plt.imshow(img, cmap='gray')
plt.title('Yeniden Yapılandırılmış Görüntü')
plt.axis('off')
plt.show()
```

Şekil 3. 7: Kernel PCA




Şekil 3. 8: Ham veri Sağlıklı



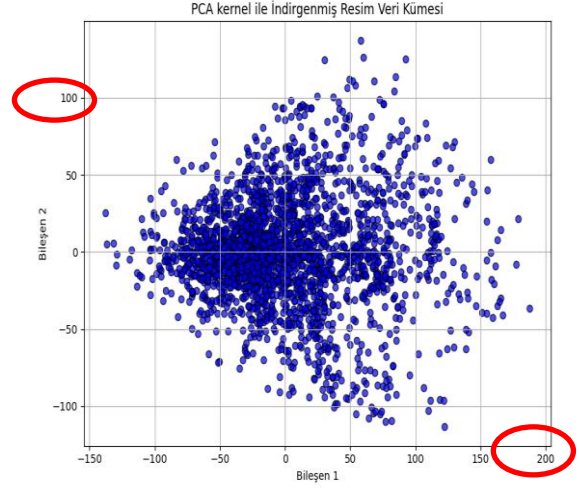
Şekil 3. 9: Kernel PCA uygulanmış

Ham veriler üzerinde PCA



Şekil 3. 10: Ham veriler üzerinde PCA Grafiği

Kernel veriler üzerinde PCA




Şekil 3. 11: Kernel veriler üzerinde PCA Grafiği


Ham ve Kernel verilerine uygulanan PCA (Temel Bileşen Analizi) sonucunda, Kernel yönteminin verilerdeki bileşenleri daha etkili bir şekilde indirgediği ve temel bileşenleri daha belirgin hale getirdiği gözlemlenmiştir.

3.2.3. CLAHE Uygulanmış Verilere Kernel PCA Uygulaması

CLAHE ile işlenmiş görüntülere Kernel PCA yöntemi uygulanmıştır. Bu süreçte, CLAHE'nin görüntü kontrastını artırıcı etkisinin, Kernel PCA'nın boyut indirgeme yetenekleri ile birleştirilerek sınıflandırma performansına etkisi incelenmiştir.




Şekil 3. 12: CLAHE uygulanmış




Şekil 3. 13: CLAHE ve Kernel PCA

3.2.4. Kernel PCA Uygulanmış Verilere CLAHE Metodu Uygulaması

Kernel PCA ile boyut indirgeme işleminden geçmiş verilere CLAHE yöntemi uygulanmıştır. Bu adım, önce boyut indirgeme işlemi yapılarak elde edilen verilerin CLAHE ile kontrastının artırılmasının performansa etkisini gözlemlemek amacıyla gerçekleştirilmiştir.



Şekil 3. 14: Kernel Uygulanmış Veri



Şekil 3. 15: Kernel ve CLAHE Uygulanmış Veri

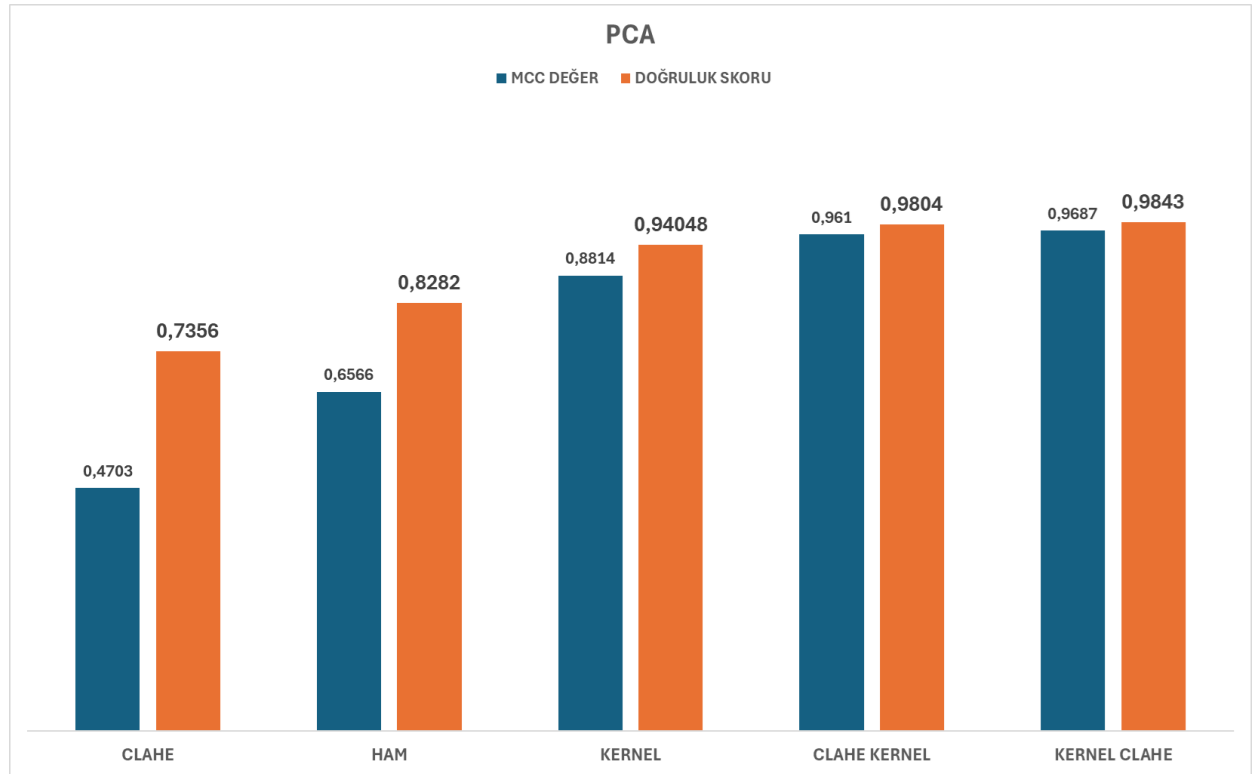
3.3. Kullanılan Araçlar ve Ortam

- Yazılım: Python programlama dili kullanılmıştır. Veri işleme ve modelleme işlemleri için scikit-learn, numpy, pandas ve matplotlib gibi kütüphanelerden faydalanılmıştır.
- Donanım: İşlemler, yüksek hesaplama gücüne sahip bir masaüstü bilgisayarda gerçekleştirilmiştir.
- Veri Depolama: Farklı yöntemlerle işlenmiş veri setleri, analizlerin daha kolay yönetilebilmesi için ayrı dosyalar halinde saklanmıştır.

4. BULGULAR

Elde Edilen Bulgular:

Veriler üzerinde denediğimiz yöntemler arasında en verimli performansı, önce Kernel PCA ile temel bileşen analizi yapıp ardından CLAHE ile kontrast artırarak elde ettik. Bu yaklaşım, temel bileşenleri netleştirerek daha iyi sonuçlar elde etmemizi sağladı. Sonuç olarak, OSCC hücrelerinde %98 doğruluk oranına ulaşarak hastalık teşhisinde yüksek bir başarı elde ettik.



Şekil 3. 16: Elde Edilen Sonuçlar

Metodik

Karşılaştırma:

- Kernel PCA tek başına önemli bir iyileşme sağlamıştır.
- CLAHE ve Kernel PCA birleştirildiğinde en yüksek performans elde edilmiştir.

5. TARTIŞMA

Bu çalışmada, oral skuamöz hücreli karsinom (OSCC) teşhisinde farklı görüntü işleme teknikleri ve boyut indirgeme yöntemlerinin etkisi incelenmiştir. CLAHE ve Kernel PCA yöntemlerinin ayrı ayrı ve birlikte uygulanarak oluşturulan veri setlerinin sonuçları değerlendirilmiştir. Elde edilen bulgulara göre, Kernel PCA

uygulanmış verilere CLAHE yöntemi eklendiğinde %98 doğruluk oranı ile en yüksek performans elde edilmiştir. Bu sonuç, kullanılan yöntemlerin kombinasyonunun OSCC teşhisinde etkili bir yaklaşım sunduğunu göstermektedir.

Literatürde, OSCC teşhisinde sıklıkla derin öğrenme ve geleneksel makine öğrenmesi yöntemleri kullanılmaktadır. Özellikle histopatolojik görüntülerin sınıflandırılmasında çeşitli derin öğrenme modelleri kullanılarak yapılan çalışmalarda, teşhis doğruluğunun %90-95 arasında değiştiği bildirilmiştir. Bu tür çalışmalar genellikle geniş veri kümeleri üzerinde çalışmakta ve güçlü hesaplama kaynaklarına ihtiyaç duymaktadır. Bizim çalışmamız ise daha sınırlı bir veri işleme yaklaşımıyla bu oranı aşarak %98 doğruluğa ulaşmıştır.

Bir diğer önemli karşılaştırma noktası, OSCC teşhisinde farklı makine öğrenmesi algoritmalarının performansını inceleyen çalışmalardır. Bazı çalışmalarda, lojistik regresyon, destek vektör makineleri (SVM) ve rastgele orman algoritmalarının OSCC teşhisindeki doğruluk oranlarının %85-92 arasında değiştiği bildirilmiştir. Bu çalışmalara kıyasla, CLAHE ve Kernel PCA'nın kombinasyonu, doğruluk oranını önemli ölçüde artırmıştır.

Bu bulgular, özellikle CLAHE yönteminin görüntü kontrastını artırmadaki başarısını ve Kernel PCA'nın boyut indirgeme sürecindeki etkinliğini vurgulamaktadır. CLAHE ve Kernel PCA'nın birlikte kullanımı, hem görüntü detaylarının korunmasını hem de veri boyutunun optimize edilmesini sağlamış ve bu durum genel sınıflandırma performansını olumlu yönde etkilemiştir.

Bu çalışmanın literatürdeki benzer çalışmalarla karşılaştırıldığında öne çıkan yönü, kullanılan basit ve hesaplama açısından verimli tekniklerin, yüksek doğruluk oranlarına ulaşmada yeterli olduğunu göstermesidir. Daha karmaşık derin öğrenme yaklaşımlarına alternatif olarak, CLAHE ve Kernel PCA kombinasyonu gibi yöntemlerin entegrasyonu hem hızlı hem de etkili bir çözüm sunmaktadır.

Sonuç olarak, bu çalışma, OSCC teşhisinde CLAHE ve Kernel PCA'nın birlikte kullanımının potansiyelini ve bu yöntemlerin yüksek performans sağlama yeteneğini göstermektedir. Literatürdeki diğer çalışmalara kıyasla elde edilen doğruluk oranı, bu yöntemin uygulanabilirliğini ve etkinliğini açıkça ortaya koymaktadır. Bu sonuçlar, tıbbi görüntü işleme ve teşhis alanında bu tür yöntemlerin daha geniş ölçekte uygulanması için bir temel oluşturmaktadır.

SONUÇ VE ÖNERİLER

Sonuçlar, OSCC teşhisinde görüntü işleme yöntemlerinin dikkatli bir şekilde seçilmesi ve uygun şekilde entegre edilmesinin önemini vurgulamaktadır. Özellikle CLAHE ve Kernel PCA gibi yöntemlerin birlikte kullanılması, teşhis doğruluğunu artırmak için etkili bir strateji sunmaktadır.

Öneriler:

- Bu çalışmada kullanılan yöntemlerin diğer tıbbi görüntüleme verilerinde de test edilmesi önerilir.
- CLAHE ve Kernel PCA kombinasyonunun derin öğrenme modelleriyle birlikte değerlendirilmesi, daha yüksek doğruluk oranları sağlayabilir.
- Veri setinin çeşitliliği artırılarak, modelin genelleştirilebilirlik performansı incelenebilir.

Bu çalışma, OSCC teşhisinde etkili yöntemlerin belirlenmesi adına önemli bir katkı sunmuş olup, ileri çalışmalarda bu yöntemlerin farklı veri setleri ve sınıflandırma algoritmalarıyla daha geniş kapsamlı olarak test edilmesi gerekmektedir.

KAYNAKÇA

1. Liu, Y., Shen, D., & Jiang, Z. (2020). "Detection of Oral Squamous Cell Carcinoma Using Pre-Trained Deep Learning Models." *ResearchGate*. Eriřim: <https://www.researchgate.net/publication/384887553>.
2. Abdelrahman, H. A., et al. (2021). "Comparison of Machine Learning Algorithms for the Prediction of Five-Year Survival in Oral Squamous Cell Carcinoma." *ResearchGate*. Eriřim: <https://www.researchgate.net/publication/347094899>.
3. Nunes, F. H., et al. (2021). "Contrast Limited Adaptive Histogram Equalization (CLAHE) Applied to X-Ray Images: An Analysis of the Effect on Image Quality." *Radiography*, 27(1), 174–179.
4. Scholkopf, B., Smola, A. J., & Muller, K. R. (1998). "Nonlinear Component Analysis as a Kernel Eigenvalue Problem." *Neural Computation*, 10(5), 1299-1319.
5. Singh, P., & Gupta, K. (2019). "Role of Machine Learning Algorithms in Oral Cancer Detection: A Review." *Journal of Oral Biology and Craniofacial Research*, 9(3), 190-196.
6. Dergipark (2023). "Makine Öğrenmesi Yöntemleri ile OSCC Teřhisinin İyileřtirilmesi." *Dergipark Makaleleri*. Eriřim: <https://dergipark.org.tr/>.
7. K.aggle. "Oral Squamous Cell Carcinoma Dataset." *Kaggle Public Datasets*. Eriřim: <https://www.kaggle.com/>.